

BTS - Statistique Inférentielle - Cours

1. Résultats préliminaires

1.1. Introduction

But : On étudie un caractère réel (par exemple : taille, énergie, ...) sur une population en cherchant, à partir d'un échantillon de cette population, à retrouver les indicateurs du caractère (moyenne, écart-type, ...).

Inférence : Opération logique par laquelle on admet une proposition en vertu de sa liaison avec d'autres propositions déjà tenues pour vraies (le Robert).

1.2. Rappels

Propriété 1 : Rappels :

- Lorsque X est une variable aléatoire :
 - $\text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$ et $\sigma(X) = \sqrt{\text{Var}(X)}$ (variance et écart-type)
- si a et b sont deux constantes :
 - $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
 - $\text{Var}(aX + b) = a^2\text{Var}(X)$
- Lorsque $S = X_1 + \dots + X_n$ est une somme de variables aléatoires :
 - $\mathbb{E}(S) = \mathbb{E}(X_1) + \dots + \mathbb{E}(X_n)$: les espérances s'ajoutent ;
 - $\text{Var}(S) = \text{Var}(X_1) + \dots + \text{Var}(X_n)$: les variances s'ajoutent **si les variables aléatoires sont indépendantes**.

Exercice 1 : Montrer que si X est une variable aléatoire d'espérance μ et d'écart-type σ , alors $Z = \frac{X - \mu}{\sigma}$ est une variable aléatoire d'espérance 0 (on dit centrée) et d'écart-type 1 (on dit réduite).
Exprimer X en fonction de Z et compléter (a, b sont des constantes): $a \leq Z \leq b \Leftrightarrow \dots \leq X \leq \dots$

Exercice 2 : X_1, \dots, X_n sont des variables aléatoires indépendantes. On note $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$.

1. Montrer que $\mathbb{E}(\bar{X}) = \frac{1}{n}(\mathbb{E}(X_1) + \dots + \mathbb{E}(X_n))$ et que $\text{Var}(\bar{X}) = \frac{1}{n^2}(\text{Var}(X_1) + \dots + \text{Var}(X_n))$
2. En déduire que si tous les X_i ont même moyenne μ , même variance v et donc même écart-type σ , on a :
 - $\mathbb{E}(\bar{X}) = \mu$;
 - $\text{Var}(\bar{X}) = \frac{v}{n}$; en déduire que $\sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}}$
3. Montrer que si les X_i suivent une loi de Bernoulli ($X = 1$ avec une probabilité p , sinon $X = 0$), alors :
 - $\mathbb{E}(S) = np$ et $\sigma(S) = \sqrt{np(1-p)}$: en effet, une variable aléatoire suivant une loi binomiale est une somme de variables aléatoires indépendantes suivant une loi de Bernoulli de même paramètre p .
 - $\mathbb{E}(\bar{X}) = p$
 - $\sigma(\bar{X}) = \sqrt{\frac{p(1-p)}{n}}$

2. Modèle

Définition 1 :

- Une **population** de taille N est modélisée par un ensemble de variables aléatoires $\{Y_1, \dots, Y_N\}$, qui représentent le caractère mesuré sur chaque individu.
On suppose, sauf cas particulier, que ces variables aléatoires suivent la même loi et sont indépendantes.
- On sélectionne n individus, qui forment un **échantillon** de taille $n < N$; on a donc un ensemble de variables aléatoires $\{X_1, \dots, X_n\}$, tel que, par exemple, $X_1 = Y_3$, $X_2 = Y_{14}$, ...
- Une **réalisation** de cette échantillon consiste à donner à chaque variable aléatoire de l'échantillon une valeur réelle, selon la loi suivie par cette variable aléatoire : on mesure le caractère étudié sur l'échantillon.
Une réalisation d'un n -échantillon se traduit donc par l'obtention de n valeurs : x_1, \dots, x_n (notées en minuscule).
- On appelle **estimateur** sur un échantillon de taille n fonction (à valeurs réelles) de n variables $h(x_1, \dots, x_n)$; par exemple $h(x_1, \dots, x_n) = \frac{1}{n}(x_1 + \dots + x_n)$ (formule de la moyenne, notée \bar{x} en statistiques), ou bien $h(x_1, \dots, x_n) = x_1 \times x_2$ (peu d'utilité).
- $h(X_1, \dots, X_n)$ étant une variable aléatoire, on peut noter $\mathbb{E}(f)$, si elle existe, l'**espérance** de l'estimateur f .
- Par essence, l'estimateur vise à approcher un paramètre de la population (par exemple la moyenne du caractère observé sur la population, une proportion, ...).
Ainsi, lorsque k est la notation du paramètre approché, on **peut noter** l'estimateur \hat{k} (avec un accent circonflexe), lorsqu'il n'y a pas d'ambiguïté.
- Pour mesurer l'erreur entre l'estimation et la réalité, on utilise le **biais** \mathbb{B} , défini par $\mathbb{B}(\hat{k}) = \mathbb{E}(\hat{k}) - k$.
Lorsque son biais est nul, on dit que l'estimateur est **sans biais**.

Propriété 2 : L'estimateur $\hat{x} = \frac{1}{n}(x_1 + \dots + x_n)$ est sans biais.

Démonstration : On note μ la moyenne sur la population entière.

$$\mathbb{B}(\hat{X}) = \mathbb{E}\left(\frac{1}{n}(X_1 + \dots + X_n)\right) - \mu = \frac{1}{n}(\mathbb{E}(X_1) + \dots + \mathbb{E}(X_n)) - \mu = \frac{1}{n}(\mu + \dots + \mu) - \mu = \frac{1}{n}n\mu - \mu = \mu - \mu = 0$$

Exercice 3 : On note \bar{X} la variable aléatoire définie par $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$ et on note V la variable aléatoire définie par $V = \bar{X}^2 - \bar{X}^2$.

On suppose que X_1, \dots, X_n ont toutes pour espérance μ et pour variance v .

Démontrer que $\mathbb{E}(V) = \frac{n-1}{n}v$; (utiliser $\mathbb{E}(T^2) = \text{Var}(T) + \mathbb{E}(T)^2$) ;

en déduire que le calcul de la variance sur l'échantillon ne fournit pas un estimateur sans biais de la variance sur la population ;

en déduire qu'un estimateur sans biais de la variance sur la population est donné par $\frac{n}{n-1}V$.

Définition 2 : Écart-type ponctuel (ou corrigé)

On utilise l'**écart-type ponctuel ou corrigé** $s_n = \sqrt{\frac{n}{n-1}}\sigma_n$ comme estimateur de l'écart-type sur la population globale ; σ_n étant l'écart-type calculé sur un échantillon de taille n .

3. Intervalle de confiance

On ne connaît pas la valeur moyenne μ d'un caractère observé sur la population.

Pour calculer l'**intervalle de confiance** I_c de la moyenne μ **de risque** α (ou **de confiance** $1-\alpha$) à partir d'un échantillon E de taille n :

confiance $1-\alpha$	0,99	0,98	0,95	0,90
risque α	0,01	0,02	0,05	0,10
z	2,58	2,33	1,96	1,65

Méthode 1 : Intervalle de confiance d'une moyenne

- on détermine la valeur z telle que $P(-z \leq Z \leq z) = 1 - \alpha$, (Z désignant une variable aléatoire suivant une loi normale centrée réduite) ;
- on calcule la moyenne \bar{x} sur l'échantillon E.

○ si l'on connaît l'écart-type σ sur la population : $I_c = \left[\bar{x} - z \frac{\sigma}{\sqrt{n}}; \bar{x} + z \frac{\sigma}{\sqrt{n}} \right]$

- si l'on ne connaît pas l'écart-type sur la population, on utilise l'écart-type ponctuel s_n (corrigé) et :

$$I_c = \left[\bar{x} - z \frac{s_n}{\sqrt{n}}; \bar{x} + z \frac{s_n}{\sqrt{n}} \right]$$

Exercice 4 : Intervalle de confiance d'une moyenne

Une machine produit des tubes dont la longueur doit être fixée. On prélève 100 tubes dans la production : On s'intéresse à la longueur moyenne μ des tubes sur l'ensemble de la production.

Longueur	[994;998[[998;1002[[1002;1006[
Nombre	26	70	4

- Déterminer un intervalle de confiance au risque de 5%.
- Déterminer un intervalle de confiance au risque de 1%.
- 1000mm est-il une moyenne réaliste ?

On ne connaît pas la valeur p d'une proportion observée sur la population.

Pour calculer l'**intervalle de confiance** I_c de la proportion p , **de risque** α (ou **de confiance** $1-\alpha$) à partir d'un échantillon E de taille n :

Méthode 2 : Intervalle de confiance d'une proportion

- on détermine la fréquence f observée sur l'échantillon E ;
- lorsque p n'est pas très proche de 0 ou 1 et que $n \geq 30$, on utilise la loi normale centrée réduite pour déterminer la valeur z telle que $P(-z \leq Z \leq z) = 1 - \alpha$, sinon on utilise une loi binomiale (cf exercice) ;

- $\sqrt{\frac{f(1-f)}{n-1}}$ étant une estimation ponctuelle de l'écart-type sur la population on a :

$$I_c = \left[f - z \sqrt{\frac{f(1-f)}{n-1}}; f + z \sqrt{\frac{f(1-f)}{n-1}} \right]$$

Exercice 5 : Intervalle de confiance d'une proportion

D'après un sondage sur $n=2501$ personnes, $\hat{p} = 51\%$ souhaitent voter pour le candidat A. On note p la proportion de personnes votantes pour A dans la population.

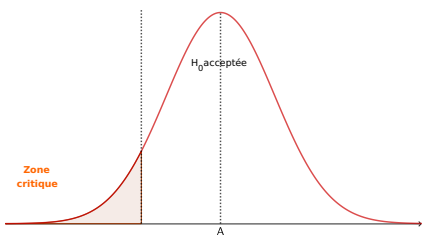
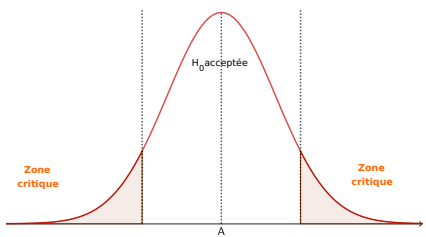
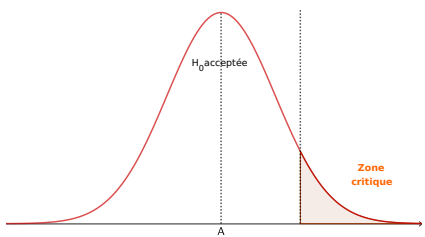
- Déterminer un intervalle de confiance au risque de 5%.
- Le candidat A est-il presque sûr (à 95%) d'être élu ?
- Déterminer la taille n qu'aurait dû avoir l'échantillon si la réponse à la question précédente est négative

4. Tests de validité d'hypothèse

On veut tester l'hypothèse qu'une certaine valeur a , existante mais non connue, sur une population donnée, correspond bien à une valeur fixée A , ou bien a «changé».

Méthode 3 :

- On prélève un échantillon de taille n dans la population.
- On énonce l'hypothèse nulle, notée H_0 , qui correspond à une situation «inchangée» : $H_0 : a = A$.
- On détermine l'hypothèse alternative, notée H_1 , qui est l'hypothèse que l'on peut montrer avec le test : 3 possibilités.
- On fixe un niveau de confiance/risque et on détermine l'intervalle de test, noté I_t , qui correspond à l'intervalle de confiance de risque α sauf dans le cas d'un test unilatéral où on remplace une de ses bornes par l'infini. L'extérieur de cet intervalle est appelé **zone critique**.
- On applique la **règle de décision** qui suit :
 - si \hat{a} , obtenu sur l'échantillon, appartient à I_t , on accepte H_0 au niveau de confiance $1 - \alpha$;
 - sinon \hat{a} est dans la zone critique, et on rejette H_0 au seuil α .

test unilatéral à gauche	test bilatéral	test unilatéral à droite
$H_1 : a \leq A$	$H_1 : a \neq A$	$H_1 : a \geq A$
$I_t = [A - h; +\infty[$	$I_t = [A - h; +A + h]$	$I_t =]-\infty; A + h]$
		

Exercice 6 : Proposer un test visant à vérifier si le rythme cardiaque ralentit suite à un don du sang.

Définition 3 : Erreur de première et deuxième espèce ; puissance (lors d'un test, il y a un risque de se tromper)

- l'erreur de **première espèce** α correspond au risque de rejeter H_0 alors qu'elle est vraie (faux positif).
- l'erreur de **deuxième espèce** β correspond au risque d'accepter H_0 alors qu'elle est fautive (faux négatif).
- La **puissance du test** est le risque de rejeter H_0 alors qu'on doit en effet rejeter H_0 .

Décision \ réalité	H_0 vraie	H_1 vraie
H_0 acceptée	bonne décision ($1 - \alpha$)	risque β 2 ^{de} espèce
H_1 acceptée	risque α 1 ^{re} espèce	bonne décision ($1 - \beta$) = puissance

Exercice 7 : Test bilatéral relatif à une proportion : Jeu de pile ou face

Pour vérifier qu'une pièce est bien équilibrée (non truquée), on jette $n=100$ fois cette pièce et on note X la variable aléatoire comptant le nombre de pile obtenus ; le but de l'exercice est de construire un test.

- Formuler l'hypothèse nulle H_0 correspondant à une pièce bien équilibrée ; quelle est l'hypothèse alternative H_1 dans le cas d'un test bilatéral.
- Calculer un intervalle de confiance au risque α de 5%, en révisant la zone critique, et en utilisant :
 - une loi binomiale
 - une loi normale ; y a-t-il réellement une différence ?
- Énoncer la règle de décision.
- On sait qu'il existe sur le marché des pièces truquées qui donnent pile dans 2 cas sur 3. Déterminer le risque β de seconde espèce (accepter que la pièce ne soit pas truquée sachant qu'elle l'est) et donner la puissance du test.
- Recommencer dans le cas d'un dé (X compte le nombre de 6), on fixe le test à 50 lancers. Y a-t-il une différence entre l'utilisation de la loi normale et binomiale pour l'intervalle de fluctuation, dans ce cas ?